

杜旭嘉

AI 应用工程师 | RAG / Agent / 后端工程化

手机: 15035925107 邮箱: 2041487752dxj@gmail.com 城市: 深圳 / 南京 / 杭州 / 成都 [GitHub](#) [国内作品集](#) [国际站](#)

求职方向: AI 应用工程师 / LLM 应用工程师 / 后端工程师 (AI 工程方向)

个人简介

主要做 [RAG](#)、[Agent Runtime](#)、业务后台和多端系统，习惯把 AI 能力接进真实业务流程，而不是只停在单接口问答。熟悉 [Python/FastAPI](#)、[Java/Spring Boot](#)、[React/Next.js](#)，能独立完成方案设计、核心开发、联调、测试和上线。

工程上更关注可追溯、可恢复、可回放和可验证：检索结果要能看到证据来源，异步任务失败后要能恢复，支付与设备回调要能幂等处理，关键路径要有测试和运行指标。

核心能力

- AI 应用开发**: 熟悉 [RAG](#)、[LangGraph](#)、工具调用、工作流编排、多通道接入和知识库治理，能把问答流程接到查询、提交、转人工等业务动作。
- 后端系统设计**: 熟悉认证、支付、任务流、后台管理、数据迁移和性能治理，常用 [FastAPI](#)、[Spring Boot](#)、[PostgreSQL](#)、[Redis](#)、[ClickHouse](#)。
- 质量与发布**: 习惯用 [pytest](#)、[Vitest](#)、[Playwright](#)、[lint/build](#)、健康检查、回归测试和回滚方案控制上线风险。
- 可验证结果**: 在中国联通项目中将活动统计接口从 [20s+](#) 降到 [4s](#)，完成 [300+](#) 表、[3 亿+](#) 记录迁移，部分核心查询从 [10s+](#) 降到 [500ms](#)。

工作经历

独立开发者 | AI 应用 / 全栈项目

2025.12 - 至今

RentBox 共享擦窗宝小程序 | [Spring Boot](#) / [React](#) / [uni-app](#)

- 面对租赁流程中支付、免押、取机、归还和设备回调并发到达的问题，设计订单状态机与生命周期服务，用 [FOR UPDATE](#) 锁、状态历史和审计日志处理支付成功、免押授权、取机、租赁中、异常、归还等状态流转。
- 接入微信支付 v3、微信支付分免押和柜机厂商 WebAPI，将支付单复用、回调 [processed_flag](#) 去重、金额不一致人工台账、设备指令记录和厂商开门/测物回调串联到同一条订单流程。
- 针对支付、退款、免押、设备重复事件和定时任务并发，加入 [Redis / JDBC](#) 幂等、分布式锁和回调回放入口，并为订单、支付、设备、免押、锁等模块编写测试，降低重复扣款、错发开锁和状态乱序风险。

论文检索任务平台 | [FastAPI](#) / [React](#) / [PostgreSQL](#)

- 在甲方 Worker 只能读写共享 [tasks](#) 表的边界下，负责用户侧任务系统；设计任务创建、状态同步、结果下载和额度扣减流程，用 [PostgreSQL LISTEN/NOTIFY](#)、[SSE keep-alive](#) 和降级轮询把异步检索进度推给前端。
- 为 Worker 状态写入设计数据库契约，在 Alembic 迁移中加入 [check constraint](#) 和 [trigger](#)，限制终态回退、成功任务缺少 [result_count](#)、终态缺少 [finished_at](#) 等脏数据。
- 实现免费/Pro 权限、活动任务占用剩余额度、成功后扣减和支付宝回调验签；通过 [SELECT ... FOR UPDATE](#)、唯一额度事件、[app_id / seller / amount](#) 校验处理并发扣减和重复回调，并用 [pytest / Vitest / Playwright](#) 验证关键路径。

智能客服运行时 | [Agent Runtime](#) / [FastAPI](#)

- 面向企业客服同时处理知识问答、业务查询、语音/RTC 和转人工的场景，设计 6 层 Runtime：渠道接入、宿主桥接、核心引擎、业务增强、插件平台、模型提供商适配。
- 实现基于 [intent_stack](#)、[page_context](#)、[business_objects](#) 和置信度分层的路由策略；在订单详情等上下文中优先走业务工具，连续低置信对话转入澄清或人工处理。
- 设计 [PluginRegistry](#) 与 7 类扩展点，覆盖路由、业务工具、人工转接、行业适配、宿主鉴权、上下文增强和响应后处理；[AuthBridge](#) 将 API Key、Session、JWT、Custom Token 统一映射到租户上下文，并用路由、插件、语音提供商测试保护关键行为。

- 面对桌面微信自动化不稳定、回复不能长时间阻塞的问题，抽象 `BaseTransport` 接入层，并用 `LangGraph` 把前台回复路径与后台成长任务分离，按回复预算控制同步路径。
- 构建 SQLite 短期记忆、Chroma 向量记忆和导出聊天记录 RAG；后台批处理负责情绪、联系人画像、向量记忆、事实抽取和导出语料同步，避免把长期记忆计算压到用户回复路径上。
- 开发 `/api/status`、`/api/readiness`、`/api/metrics`、配置审计、成本分析、回复策略、备份恢复和离线 eval；敏感关键词、静默时段、群聊白名单和新联系人策略进入人工审批队列，降低误发消息风险。

中软国际 | 企业知识库 RAG / Agent 工作台 | 后端 / 全栈工程师

2025.04 - 2025.09

- 企业知识库问答需要同时给出答案、证据和检索诊断；设计结构检索、全文检索、向量检索 3 路召回，结合 `query rewrite`、加权 `RRF` 和 `rerank`，返回 `citations`、`grounding_score`、`trace_id` 与候选来源。
- 将 Gateway 问答流程迁移到 `LangGraph` 运行时，使用 `checkpoint`、`interrupt/resume`、人工确认和 `step_events` 记录执行过程；失败重试时复用检索与生成 `checkpoint`，避免同一问题重复检索和重复计费。
- 建设 ingest 与知识库治理工作台，处理多知识库、多源连接器、本地目录、Notion、Web、飞书、钉钉和 SQL 数据源；提供 `chunk` 拆分/合并/禁用、`retrieve/debug` 调试、Prompt Injection 防护、背压保护和 `smoke-eval / regression gate` 回归检查。

国家骨科临床研究中心 | SubMed 医学论文检索小程序 | 后端开发实习生

2024.08 - 2024.10

- 面向医学专家检索 PubMed 文献、筛选高价值论文和持续跟踪研究主题的需求，参与 SubMed 小程序后端接口设计与小程序联调，覆盖检索、推荐、订阅、收藏、深度分析、下载和分享。
- 对接 `/api/articles/ai_search`、`/api/articles/ai_search_test`、`/api/deep_analysis`、`/api/recommend_paper`、`/api/favorite` 等接口，在论文详情页展示 DOI、IF、CAS、JCR、SCI、AI 关键词、相关推荐和 PDF 下载入口。
- 设计检索主题页、分页论文列表、订阅配置和推送历史页面；通过搜索历史、Topic 选择、订阅频率和推送状态管理，把一次性搜索改为可持续跟踪的科研信息流。

中国联通陕西省分公司 | 触点赋能中心 / 陕西运营平台 / 数据中台 | 后端开发实习生

2024.05 - 2024.08

- **触点赋能中心**：改造对外 API 二次授权认证，并治理活动统计查询；通过 `OLTP / OLAP` 分离和 `ClickHouse` 聚合分析，将活动统计接口从 `20s+` 降到 `4s`。
- **陕西运营平台**：开发能力管理页面与后端逻辑，处理请求/响应加解密；维护陕西号码复通接口，并完成按模型扫描号码和自动开机的二次开发。
- **数据中台**：完成 `300+` 表、`3 亿+` 记录迁移和一致性校验，用 `xxl-job` 执行每日动态更新；重写聚合 SQL、增加覆盖索引和缓存后，部分核心查询从 `10s+` 降到 `500ms`，发布耗时从 `30 分钟` 降到 `5 分钟`。

精选项目

RentBox 共享擦窗宝小程序 | Spring Boot / React / uni-app / MySQL / Redis

- 面对租赁业务中支付、免押授权、取机、归还、退款和设备事件异步到达的问题，设计 `OrderStateMachine` 与 `OrderLifecycleService`，用 `FOR UPDATE`、状态历史和审计日志管理订单状态迁移，避免晚到回调把订单改回旧状态。
- 接入微信支付 v3、微信支付分免押和柜机厂商 WebAPI；在 `OrderPaymentService`、`WechatPayScoreDepositFreeGateway`、`DepositFreeIntegrationCallbackController` 中处理支付单复用、金额校验、免押授权、解押和退款回调。
- 针对支付通知、退款通知、设备开门/测物回调和定时任务并发，使用 `RedisIdempotencyService`、JDBC 幂等记录、`processed_flag` 和回调重放入口，把重复扣款、重复开门、重复处理控制在服务层。
- 为订单、支付、设备指令、免押、锁和回调回放编写测试，核心风险点可通过本地用例复现；设备侧以 `DeviceCommandService` 记录命令下发、厂商响应和异常工单，便于排查真实柜机联调问题。

论文检索任务平台 | FastAPI / React / PostgreSQL / SQLAlchemy

- 在甲方 Worker 只能读写共享 `tasks` 表的边界下，负责用户侧任务系统，设计任务创建、状态同步、结果下载、额度扣减和支付回调模块，让前端不直接依赖 Worker 进程状态。
- 使用 PostgreSQL `LISTEN/NOTIFY` 驱动任务状态推送，后端提供单任务、多任务和全局活动任务 SSE；连接空闲时发送 keep-alive，通知缺失时回退到短轮询，前端异常时继续使用任务列表与状态查询。
- 通过 Alembic 迁移为 `tasks` 增加 `check constraint` 与触发器，限制终态回退、成功任务缺少 `result_count`、终态缺少 `finished_at`、结果数为负等脏数据，并通过 `pg_notify('task_status_changed', ...)` 通知后端监听器。

- 设计免费/Pro 额度模型和支付宝支付回调，使用 `SELECT ... FOR UPDATE`、唯一额度流水、`app_id / seller / amount` 校验处理并发扣减和重复通知；后端 `pytest`、前端 `Vitest` 与 `Playwright` 用例覆盖任务、支付、额度和 SSE 行为。

智能客服运行时 | FastAPI / Agent Runtime / WebSocket / Plugin System

- 面向企业客服同时接入文本、语音轮次、RTC 实时通话和人工接手的场景，设计 6 层 Runtime：渠道接入、宿主桥接、核心引擎、业务上下文、插件平台和模型/语音提供商适配。
- 在 `RoutingService` 与 `SessionService` 中维护 `intent_stack`，结合 `page_context`、`business_objects` 和置信度分层做路由决策；相同意图合并低置信计数，连续低置信或用户明确要求时转人工。
- 设计 `PluginRegistry` 和 7 类扩展点，包括路由策略、业务工具、人工接手、行业适配、鉴权桥、上下文补充和响应后处理；宿主系统可按优先级注册插件，而不是改 Runtime 主干代码。
- 在 `AuthBridgePlugin` 中统一 API Key、Session/Cookie、JWT/Bearer、Custom Token 与自定义 Header 桥接；语音/RTC 模块支持 ASR、TTS、房间状态机、打断和超时，相关行为由路由、插件、鉴权和语音提供商测试固定。

微信智能助手 | Quart / Electron / LangGraph / ChromaDB

- 面向 Windows 微信自动化不稳定、回复路径不能长时间阻塞的场景，抽象 `BaseTransport` 接入层，将 WCFerry 适配与 Bot 主循环解耦，桌面端和 Web 控制台共用 Quart 后端状态。
- 使用 `LangGraph` 组织上下文加载、提示词构建、模型调用和回写，将前台回复与后台成长任务分开：前台按回复预算生成消息，后台再处理情绪、画像、事实抽取、向量记忆和导出聊天 RAG。
- 构建 SQLite 短期记忆、Chroma 向量记忆和导出聊天记录 RAG；长记忆写入、embedding、联系人画像和导出语料同步放到后台任务，避免把高成本计算放进用户回复路径。
- 提供 `/api/status`、`/api/readiness`、`/api/metrics`、配置审计、成本分析、回复策略、备份恢复和离线 eval；敏感关键词、静默时段、群聊白名单和新联系人策略进入人工审批队列，减少误触发消息风险。

RAG-QA System | FastAPI / Vue / LangGraph / Qdrant

- 面向企业知识库“答案必须能追溯来源”的需求，开发多知识库问答系统，包含文档上传、异步解析、统一聊天、SSE 流式回答、引用返回和检索诊断信息。
- 在检索服务中实现结构化检索、全文检索、向量检索三路召回，结合 query rewrite、RRF 和 rerank 返回候选来源、`citations`、`grounding_score`、耗时分解和 `trace_id`。
- 将 Gateway 问答流程迁移到 `LangGraph`，使用 `checkpoint`、`interrupt/resume`、人工确认和 `step_events` 记录执行过程；失败重试时复用检索与生成 checkpoint，减少同一问题重复检索和重复计费。
- 建设知识库治理能力：本地目录、Notion、Web、飞书、钉钉和 SQL 连接器，chunk 拆分/合并/禁用、`retrieve/debug`、Prompt Injection 防护、429 背压返回，以及 `correctness / faithfulness / citation_alignment` 评测。

EasyCloudPan | Spring Boot / React / PostgreSQL / Redis / MinIO

- 面向个人云盘的大文件、弱网中断和重复上传场景，设计分片上传、秒传、断点续传和 SSE 状态回传；`ChunkUploadService` 用 Redis 记录分片状态并限制单文件并发，`QuickUploadService` 通过 `fileMd5 -> fileId` 复用已有对象。
- 在上传和转码状态上使用受管异步执行与 `SseEmitter`，前端从轮询改为长连接接收进度；连接生命周期、超时和异常返回由服务端统一管理，避免状态任务长期占用线程。
- 设计 `HMAC-SHA256 + timestamp + nonce` 请求签名，nonce 写入 Redis 拦截重放；同时接入 JWT 双 Token、黑名单、Magic Number 文件类型校验、多租户隔离和文件访问切面。
- 引入 Caffeine + Redis + DB 多级缓存、MinIO/S3 主存储与本地回退、Actuator/Micrometer/Prometheus/Grafana 指标；项目文档记录 API `P95 <500ms`、`P99 <1s`，数据库查询 `P95 <100ms`，上传成功率 `>99.5%`。

SubMed 医学论文检索小程序后端 (wereader) | Django / Celery / Redis / MySQL

- 面向医学专家检索 PubMed 文献、筛选高价值论文和持续跟踪研究主题的需求，参与 SubMed 小程序后端开发，提供首页、主题列表、搜索、推荐搜索、论文详情、收藏、订阅、积分、订单和管理后台接口。
- 在 `Paper`、`Journal`、`Task`、`Subscription`、`PushHistory` 等模型中管理 PMID、DOI、下载链接、JCR/IF、CAS 分区、推送任务和用户订阅配置；`build_fe_json` 统一输出小程序需要的论文展示字段。
- 实现 `articles_ai_search` 与 `articles_ai_search_2`：先把用户问题转为中英文检索词，再调用 `PubMedSpider` 拉取候选论文，使用 GPT 对摘要相关度二次打分，按 `ai_score` 排序并保存命中的 PubMed 数据。
- 参与校地合作小程序开发与交付，支持多方向混合搜索、Redis 查询缓存、Celery 异步缓存刷新、深度分析收藏和订阅推送历史，将一次性文献检索延伸为研究主题的持续跟踪。

IPA 方言语音转写原型 | Flask / PyTorch / Transformers / torchaudio

- 面向方言语音采集后的 IPA 转写整理，开发本地 Web 原型，支持批量上传、录音上传、示例音频、单文件二次转写、流式进度和结果导出。

- 使用 `transformers.pipeline` 加载本地 ASR checkpoint，并按 CUDA/CPU 自动选择设备；`AudioLoader` 基于 `torchaudio` 读取音频字节、重采样到 16kHz 单声道，必要时通过 `ffmpeg` 转成标准 WAV。
- 将音标转写拆成声母、韵母和声调：从 Excel 读取声母集合、声调集合和声调数字映射，`split_ipa` 按位置规则处理兼类字符，再把识别结果缓存到内存供后续导出使用。
- 批量识别时用 `ThreadPoolExecutor` 并发加载音频、后台线程异步保存原始文件；提供 SSE 进度事件、模板 Excel 校验、`openpyxl` 导出和方正国际音标字体设置，方便把转写结果交给研究人员复核。

九州通四向穿梭车路径规划系统 | Python / A* / PyQt5 / multiprocessing

- 面向医药物流仓库中的四向穿梭车调度，基于 42×27 仓储网格建模道路、墙壁、无货货架和有货货架，负责 A* 寻路、地图编辑、多车路径展示和冲突处理原型。
- 实现 `A_Search`：使用 open/close 列表、F/G/H 值、曼哈顿距离启发函数和方向一致性选择策略；通过 `point._new_` 让同坐标节点复用同一实例，减少搜索过程中的重复对象。
- 针对空车和载货两种场景，在 `getAroundPoint` 中动态切换可通行规则：空车可通过货架区，载货时避开已有货物的满货架；`process()` 使用 `yield` 输出搜索步骤，供界面逐帧显示 open/close 和当前路径。
- 设计 `Vehicle` 类、多车配置、进程池并发搜索和基于优先级的时间步冲突处理；低优先级车辆在冲突点前插入等待动作，PyQt5 侧通过 `QBasicTimer`、地图保存/加载和颜色编码展示调度结果。

技能栈

方向	技术栈
AI 工程	<code>RAG</code> / <code>LangGraph</code> / <code>Agent Runtime</code> / 工具调用 / 工作流编排 / OpenAI API / 向量检索 / 引用溯源
后端与数据	<code>Python</code> / <code>FastAPI</code> / <code>AsyncIO</code> / <code>Pydantic</code> / <code>SQLAlchemy</code> / <code>Java</code> / <code>Spring Boot</code> / <code>MyBatis</code> / <code>PostgreSQL</code> / <code>MySQL</code> / <code>Redis</code> / <code>ClickHouse</code>
全栈交付	<code>React</code> / <code>Next.js</code> / <code>TypeScript</code> / <code>Vite</code> / <code>uni-app</code> / REST API / 支付集成 / 管理后台 / 多端协同
工程质量	<code>pytest</code> / <code>pytest-asyncio</code> / <code>Vitest</code> / <code>Playwright</code> / <code>Prometheus</code> / <code>Grafana</code> / 健康检查 / 发布回滚 / <code>lint</code> / <code>build</code> / E2E

教育背景

南阳理工学院 | 数据科学与大数据技术

2021.09 - 2025.06

- GPA `3.8/4.5` , `Top 5%`
- 校级三好学生、校级优秀学生干部、院级奖学金